

Прикладная статистика

Интерпретации вероятности. Точечные оценки

Денис Деркач, Влад Белавин

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

В этой лекции

- ▶ Интерпретации вероятности: байесовский и частотный вывод
- ▶ Точечные оценки:
 - метод моментов;
 - метод максимального правдоподобия;
 - метод максимальной апостериорной вероятности.

Вероятность



Что такое вероятность

Вероятность - важнейшее понятие в современной науке, тем более что никто не имеет ни малейшего представления о том, что оно означает.

– Бертран Рассел (1929)

Математический подход

- ▶ Аксиомы Колмогорова:

- $\mathcal{P}(A) > 0$;
- $\mathcal{P}(\text{True}) = 1$;
- $\mathcal{P}(A \cup B) = \mathcal{P}(A) + \mathcal{P}(B)$ (если A и B не пересекаются).

- ▶ Теорема Байеса:

- $\mathcal{P}(A|B) = \frac{\mathcal{P}(B|A)\mathcal{P}(A)}{\mathcal{P}(B)}$, где $\mathcal{P}(A|B)$ - вероятность A при условии выполненного B .

- ▶ Полная вероятность:

- $\mathcal{P}(A) = \sum_n \mathcal{P}(A \cap B_n) \mathcal{P}(B_n)$, где B_n разбиение всего пространства.

Выводы

- ▶ Вероятность – концепция, которая существует без привязки к математическим объектам.
- ▶ В прикладной статистике используется математизированная версия концепции, часто сводимая к аксиомам Колмогорова.
- ▶ Интерпретация полученных математических выражений с точки зрения реального мира – задача дополнительных умозаключений.

E. T. Jaynes, Probability Theory: The Logic of Science

Интерпретация вероятности




Зачем интерпретировать числа

- ▶ Прикладная статистика объединяет математическую теорию и реальные задачи.
- ▶ Для реальной жизни важно не только численное значение, но и понимание, насколько это значение отвечает на поставленный вопрос.
- ▶ Вопрос интерпретации близок к философии, но имеет прямое отношение к результатам (как мы увидим позднее).

The Oxford Handbook of Probability and Philosophy

Постановка (обратной) задачи



X (данные)

Наблюдаемые

Вероятностная модель

статистический вывод

θ (параметры)

Ненаблюдаемые

[Ryan Giordano's blog](#)

Частотная интерпретация

Классическая (частотная, frequentist):

$$\mathcal{P}(X) = \lim_{N \rightarrow \infty} \frac{n}{N}$$


где n – число произошедших событий X из N попыток.

- ▶ Случайность объективна.
- ▶ Вывод построен на большом количестве экспериментов.
- ▶ Параметры фиксированы.

Частотная интерпретация: следствия

- ▶ Параметры фиксированы.
- ▶ Вывод базируется на идее случайности данных.
- ▶ Математический результат:

$$\mathcal{P}(X|\theta)$$




Байесовская интерпретация

$\mathcal{P}(X)$ – степень уверенности в исходе X .

- ▶ Случайность – мера нашего незнания.
- ▶ Вывод построен на одном эксперименте.
- ▶ Параметры имеют неопределённость, то есть случайны с нашей точки зрения.

Байесовская интерпретация: следствия

- ▶ Параметры случайны (с нашей точки зрения).
- ▶ Вывод базируется на идее фиксированных данных.




Байесовская интерпретация: следствия

- ▶ **Априорное** знание распределения параметров $\mathcal{P}(\theta)$.
- ▶ Для каждого θ есть распределение данных $\mathcal{P}(X|\theta)$.
- ▶ **Используем** теорему Байеса:

$$\mathcal{P}(\theta|X) = \frac{\mathcal{P}(X|\theta)\mathcal{P}(\theta)}{\mathcal{P}(X)}$$

- ▶ Получаем **апостериорное** распределение параметров θ .




Байесовская интерпретация: следствия

Априорное

Измерение

апостериорное



Сравнение интерпретаций

Классическая

- ▶ Произвол в выборе метода.
- ▶ Использует асимптотические характеристики.
- ▶ Удовлетворяет аксиомам Колмогорова
- ▶ Ответ метода: $\mathcal{P}(X|\theta)$.

Байесовская

- ▶ Произвол в выборе априорной вероятности.
- ▶ Использует теорему Байеса.
- ▶ Удовлетворяет аксиомам Колмогорова
- ▶ Ответ метода: $\mathcal{P}(\theta|X)$.

Какой вопрос мы обычно задаём?

B. Efron, T. Hastie, Computer Age Statistical Inference

Броски монетки

Дано: 14 бросков монет, 10 раз выпал орёл.

Найти: Вероятность двух следующих орлов подряд.

Броски монетки: частотное решение

Дано: 14 бросков монет, 10 раз выпал орёл.

Найти: Вероятность двух следующих орлов подряд.

Оценим вероятность выпадения орла:

$$\hat{p} = \frac{10}{14} \approx 0.71$$

Тогда вероятность двух орлов подряд:

$$\hat{p}^2 \approx 51\%$$

Броски монетки: байесовское решение (1/2)

Дано: 14 бросков монет, 10 раз выпал орёл.

Найти: Вероятность двух следующих орлов подряд.

Оценим вероятность получения данных для какого-то p :

$$\mathcal{P}(X|p) = \binom{14}{10} p^{10} (1-p)^4$$

Априорная вероятность для p :

$$p \sim \text{Uniform}(0; 1) = \text{Beta}(p, 1, 1)$$

Вероятность $\mathcal{P}(X)$ не зависит от p и (для нас) константа.

Тогда:

$$\mathcal{P}(p|X) = \frac{\mathcal{P}(X|p)\mathcal{P}(p)}{\mathcal{P}(X)} \sim p^{10}(1-p)^4$$

Броски монетки: байесовское решение (2/2)

Дано: 14 бросков монет, 10 раз выпал орёл.

Найти: Вероятность двух следующих орлов подряд.

Найдём ответ:

$$\mathcal{P}(2 \text{ орла} | X) = \int P(2 \text{ орла} | p) P(p | X) dp = \int p^{12} (1 - p)^4 dp \approx 49\%$$

Броски монетки: обсуждение

Дано: 14 бросков монет, 10 раз выпал орёл.

Найти: Вероятность двух следующих орлов подряд.

- ▶ Оба решения правильные.
- ▶ Заменой **априорного** распределения в байесовском методе можно добиться совпадения ответов.
- ▶ Интерпретация вероятностей имеет решающее влияние на ответ.

<https://www.behind-the-enemy-lines.com/2008/01/are-you-bayesian-or-frequentist-or.html>

Показания вольтметра

- ▶ Инженер снимает показания с нескольких образцов:

$$x_i \sim N(\mu, 4).$$

- ▶ Измерения $82 < x_i < 99$ В, несмещённая оценка μ выборочным средним $\bar{x}=92$ В.
- ▶ Оказывается, что вольтметр не может снимать показания больше 100 В (залипает стрелка).
- ▶ **Частотный подход** говорит, что анализ необходимо повторить с учётом новой информации.
- ▶ **Байесовский подход** использует новое априорное распределение.



Выводы

- ▶ Основные интерпретации вероятностной картины ведут к принципиально разным ответам.
- ▶ Ни одна интерпретация не является единственно правильной.
- ▶ Применение тех или иных методов зависит от поставленного вопроса.

Deborah Mayo, Statistical Inference as Severe Testing (How to Get Beyond the Statistics Wars)

Точечные оценки



Постановка задачи

- ▶ **Задача параметрического оценивания:** необходимо оценить значение $T(\theta)$, где T — некоторая функция параметра θ :

$$T: \Theta \rightarrow \mathcal{Y}$$

$$\theta \mapsto T(\theta)$$

То есть, необходимо построить оценку $\hat{T}$ по имеющейся выборке X .

$$\hat{T}: \mathcal{X} \rightarrow \hat{\mathcal{Y}}.$$


- ▶ Оценка должна быть:
 - Состоятельной $\hat{T}_n \rightarrow T$.
 - Несмещённой $\mathbb{E}\hat{T}_n - T = 0$.
 - Эффективной $\text{Var}\hat{T}_n \rightarrow \min$.

Выборочное среднее

Для iid $x_i \sim f$ величин, мы можем построить выборочное среднее

$$\bar{x} = \frac{1}{n} \sum x_i.$$

В предположении $f \sim N(\mu, \sigma)$, $\bar{x}$ является хорошей оценкой для μ .



Распределение Коши

$$f(x; x_0, \gamma) = \frac{1}{\pi} \left(\frac{\gamma}{(x - x_0)^2 + \gamma^2} \right)$$



γ – параметр масштаба;

x_0 – параметр сдвига.

Параметр сдвига оценивается мерой центральной тенденции.

Но:

$$\mathbb{E}x = \infty$$



Устойчивые центральные тенденции

- ▶ **Выборочная медиана;**
- ▶ **α -усечённое выборочное среднее:**
Убрать α экстремальных значений
- ▶ **α -винзоризованное выборочное среднее**
Заменить α экстремальных значений на последние не экстремальные.
- ▶ **оценка Ходжеса-Лемана**

Медиана выборки: $\{\frac{x_i+x_j}{2}; 1 \leq i \leq j \leq n\}$

Метод моментов

Пусть θ – параметр распределения $F_\theta(x)$, определим **j момент**:

$$\alpha_j = \mathbb{E}(X^j) = \int x^j dF_\theta(x),$$

и **j -й выборочный момент** выборки $x_1, \dots, x_n \sim F_\theta$ согласно формуле:

$$\hat{\alpha}_j = \frac{1}{n} \sum x_i^j.$$

Тогда

$$\alpha_j(\hat{\theta}) = \hat{\alpha}_j$$

Позволяет получить несмещённую асимптотически нормальную оценку.

Пример: метод моментов

Пусть $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$, тогда

$$\alpha_1 = \mathbb{E}(X_1) = \mu,$$

$$\alpha_2 = \mathbb{E}(X_1^2) = \text{Var}(X_1) + (\mathbb{E}(X_1))^2 = \sigma^2 + \mu^2,$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i,$$

$$\hat{\sigma}^2 + \hat{\mu}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

Решая систему уравнений, получаем, что

$$\hat{\mu} = \overline{X}_n \quad \text{и} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2.$$

Вывод

- ▶ При анализе реальных данных важную роль играет робастность оценки.
- ▶ Для построения робастных оценок можно воспользоваться одним из нескольких подходов, известных в литературе*.

Оценка максимального правдоподобия



Оценка максимального правдоподобия

Пусть есть iid выборка $x_1, \dots, x_n \sim f_\theta$, θ – параметр плотности распределения f_θ . Функцией правдоподобия будем называть:

$$\mathcal{L}_n(\theta) = \prod_{i=1}^n f_\theta(x_i).$$

Оценка максимального правдоподобия (ОМП) определяется как такое значение $\hat{\theta}_n$ параметра θ , которое максимизирует $\mathcal{L}_n(\theta)$.

Оценка максимального правдоподобия

ОМП состоятельная, то есть $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta_*$, где θ_* — реальное значение параметра θ ;

ОМП не зависит от параметризации, то есть $\hat{\theta}_n$ — ОМП для θ , тогда $g(\hat{\theta}_n)$ — ОМП для $g(\theta)$;

ОМП асимптотически нормальна: $(\hat{\theta} - \theta_*)/\hat{se} \rightsquigarrow \mathcal{N}(0, 1)$;

ОМП асимптотически оптимальна или эффективна (при достаточно большом объеме выборки ОМП имеет меньшую дисперсию).

Правдоподобие распределения Вейбулла


$$F(t, \alpha, \beta, \eta) = \begin{cases} 1 - e^{-((t-\alpha)/\eta)^\beta}, & t > \alpha \\ 0, & t \leq \alpha \end{cases}$$

Найдём максимум:

$$\sum_{i=1}^n \left[\frac{1}{\beta} + \ln(t_i - \alpha) - \ln(\eta) - \left(\frac{(t_i - \alpha)}{\eta} \right)^\beta \ln \left(\frac{(t_i - \alpha)}{\eta} \right) \right] = 0$$

$$\sum_{i=1}^n \left[-\frac{\beta}{\eta} + \left(\frac{\beta}{\eta} \right) \left(\frac{(t_i - \alpha)}{\eta} \right)^\beta \right] = 0$$

$$\sum_{i=1}^n \left[-\frac{(\beta - 1)}{(t_i - \alpha)} + \left(\frac{\beta}{\eta} \right) \left(\frac{(t_i - \alpha)}{\eta} \right)^{\beta-1} \right] = 0$$



Найти решения этой системы уравнений не представляется возможным.

Вывод

- ▶ Оценка максимального правдоподобия обладает множеством полезных теоретических свойств.
- ▶ На практике даже довольно простые функции могут привести к смещённым оценкам.
- ▶ Есть зависимость от модельных предположений.

Оценка апостериорного максимума



Построение оценки

- ▶ ОМП определяет значения параметров, при которых наши данные наиболее вероятны.
- ▶ На самом деле, мы обычно задаёмся вопросом, какие значения параметров наиболее вероятны:

$$f(\theta|X) = f(X|\theta)g(\theta)/h(X)$$

где f , g и h – соответствующие функции распределения.

- ▶ **Оценка апостериорного максимума (МАР)** определяется как значение $\hat{\theta}_n$ параметра θ , которое максимизирует $f(\theta|X)$.

Связь с ОМП

- ▶ МАР и ОМП очевидно связаны:

$$f(\theta|X) = \frac{f(X|\theta)g(\theta)}{h(X)} = \prod \frac{f(x_i; \theta)g(\theta)}{h(x)} \sim c \prod f(x_i; \theta)g(\theta)$$

- ▶ Логарифмируем:


$$\log f(\theta|X) = \log(g(\theta)) + \sum \log(f(x_i|\theta)).$$

- ▶ Получается, что значение МАР оценки и значение ОМП совпадают с точностью до априорной оценки $\log(g(\theta))$.
- ▶ Как выбрать $g(\theta)$?

Сопряжённые априорные распределения

Функция правдоподобия

Априорное распределение


$$f(\theta|X) = \frac{f(X|\theta)g(\theta)}{h(X)}$$

Распределение данных $h(X) = \int f(X|\theta)g(\theta) d\theta$

Можно подобрать такое априорное распределение $g(\theta)$, которое не выводит при умножении на $f(x|\theta)$, оставляет $f(\theta|X)$ в том же классе распределений.

Семейство $g(\theta)$ будем называть **сопряжённым** к $f(x|\theta)$.

Задача про монетку


$$\mathcal{P}(p|X) = \frac{\mathcal{P}(X|p)\mathcal{P}(p)}{\mathcal{P}(X)}$$

Для s орлов и f решек

$$\mathcal{P}(X|p) = \binom{s+f}{f} p^s (1-p)^f$$

$$\mathcal{P}(p) = \text{Uniform}(0; 1) = \frac{1}{B(\alpha, \beta)} p^{\alpha-1} (1-p)^{\beta-1} \equiv \text{Beta}(p, \alpha, \beta)$$

$$B(\alpha, \beta) = \int p^{\alpha-1} (1-p)^{\beta-1}$$



Задача про монетку

$$\mathcal{P}(p|X) = \frac{\mathcal{P}(X|p)\mathcal{P}(p)}{\mathcal{P}(X)}$$

Перемножив и нормировав, получим

$$\mathcal{P}(p|X) = \frac{1}{B(s+\alpha, f+\beta)} p^{s+\alpha-1} (1-p)^{f+\beta-1} \equiv \text{Beta}(p, \alpha + s, \beta + f)$$

Beta – **сопряжённое априорное распределение** для распределения Бернулли.

Вывод

- ▶ MAP позволяет учесть предыдущие измерения.
- ▶ Результат MAP зависит от параметризации.
- ▶ Подбор априорного распределения может значительно ускорить решение задачи*.

Общий вывод

- ▶ Вероятности можно интерпретировать по-разному. Лидирующие интерпретации – Классическая и Байесовская.
- ▶ Для точечной параметрической оценки существуют несколько способов: метод моментов, метод максимального правдоподобия, метод апостериорного максимума.
- ▶ Каждый метод имеет проблемы при применении к реальным данным.