

Прикладная статистика

Обобщённые линейные модели

Денис Деркач, Влад Белавин

Лаборатория методов анализа больших данных (Lambda)



LAMBDA • HSE

Весна 2022

В этой лекции

- ▶ Линейные модели
 - робастные оценки.
- ▶ Экспоненциальные семейства
- ▶ Регрессия с бинарными откликами.
- ▶ Обобщённые линейные модели
 - постановка задачи;
 - поиск и интерпретация параметров.

Регрессия

Регрессия — метод изучения зависимости между откликом Y и регрессором X (признак, независимая переменная).

Один из способов оценить зависимость:

$$r(x) = \mathbb{E}(Y|X = x) = \int y f(y|x) dy.$$

Задача состоит в том, чтобы построить оценку $\hat{r}(x)$ функции $r(x)$ по данным

$$(Y_1, X_1), \dots, (Y_n, X_n) \sim F_{X,Y},$$

где $F_{X,Y}$ — совместное распределение X и Y .

Линейные модели



Стандартная линейная регрессия

$$Y = X\beta + \varepsilon$$

- › Y - вектор наблюдаемых зависимых переменных (откликов);
- › X - матрица независимых переменных (дизайн эксперимента);
- › β - матрица, включающая параметры, представляющие интерес для исследования;
- › ε - матрица случайных ошибок.

NB: случайные ошибки распределены нормально и не зависят друг от друга.

Матрица ошибок



- ▶ Стандартные выводы делаются в предположении постоянной дисперсии нормального шума (**гомоскедастичность**):

$$\epsilon \sim N(0, \sigma^2 I).$$

- ▶ Зачастую дисперсия шума меняется от точки к точке (**гетероскедастичность**):

$$\epsilon \sim N(0, \sigma^2 D),$$

где D - диагональная матрица.



Взвешенные методы

- ▶ Для простого случая известных σ и D_i :

$$Y_i \sim N(\mu, \sigma^2 D_i).$$

- ▶ Лог-правдоподобие:

$$-2 \log \mathcal{L}(\mu|Y, \sigma) = \sum \frac{(Y_i - \mu)^2}{\sigma^2 D_i} + n \log(2\pi\sigma^2) + \sum \log D_i.$$

- ▶ Приравнивая производную нулю:

$$-2 \sum \frac{(Y_i - \hat{\mu})}{\sigma^2 D_i} = 0$$

$$\hat{\mu} = \sum \frac{Y_i}{D_i} / \sum \frac{1}{D_i}$$

Взвешенная регрессия

- ▶ Для модели $Y = X\beta$:

$$\begin{aligned} -2 \log \mathcal{L}(\beta, \sigma | Y) &= \sum \frac{(Y_i - \sum \beta_j X_{ij})^2}{\sigma^2 D_i} = \\ &= \frac{1}{\sigma^2} (Y - X\beta)^T W (Y - X\beta), \end{aligned}$$

где $W = D^{-1}$

- ▶ Приравнивая производную нулю:

$$\begin{aligned} -2X^T W (Y - X\hat{\beta}_W) &= 0 \\ \hat{\beta}_W &= (X^T W X)^{-1} X^T W Y. \end{aligned}$$

Ненормальные распределения ошибок

- ▶ Данные могут иметь:
 - Некоторое количество выбросов.
 - Ненормальное распределение шума.
- ▶ Для небольшого количества выбросов:
 - Используется абсолютное значение вместо квадрата:

$$\hat{\mu} = \operatorname{argmin}_{\mu} \sum |Y_i - \mu|$$

в этом случае вместо среднего регрессия будет предсказывать медиану.

- Усечённое среднее (и прочие робастные оценки).

Заключение

- ▶ Обычная линейная регрессия имеет хорошо определённые границы применимости.
- ▶ Реальные данные зачастую не входят в эти границы.
- ▶ В некоторых случаях существует возможность учесть специфические проблемы в данных, использовать робастные оценки.

Экспоненциальные семейства



Экспоненциальное семейство

Семейство распределений $\{P_\theta : \theta \in \Theta\}$, $\Theta \subset \mathbb{R}^k$ называется (k -параметрическим) экспоненциальным семейством на $\mathbb{R}^q$, если существуют такие вещественнозначные функции:

- › $\eta_1, \dots, \eta_k$ и B от θ ,
- › $T_1, T_2, \dots, T_k$ и h от $x \in \mathbb{R}^q$,

такие, что плотность вероятности этого семейства записывается:

$$p_\theta(x) = h(x) \exp \left[\sum_{i=1}^k (\eta_i(\theta) T_i(x) - B(\theta)) \right]$$

Экспоненциальное семейство (дисперсионное)

Для $y_1, \dots, y_n$:

$$f(y_i; \theta_i, \phi) = \exp\{[y_i \theta_i - b(\theta_i)] / a(\phi) + c(y_i, \phi)\}$$

θ - канонический параметр;

ϕ - дисперсионный параметр;

$b(.)$ - кумулятивная функция.

При $a(\phi) = 1$ и $c(y_i, \phi) = c(y_i)$ получим стандартное определение экспоненциального семейства.

Экспоненциальное семейство (дисперсионное)

Для $y_1, \dots, y_n$:

$$f(y_i; \theta_i, \phi) = \exp\{[y_i \theta_i - b(\theta_i)] / a(\phi) + c(y_i, \phi)\}$$

При этом, исследуя ОМП, мы получим:

- ▶ $\mathbb{E}(Y_i) = b'(\theta_i) = \mu_i$
- ▶ $\text{Var}(Y_i) = b''(\theta_i)a(\phi) = a(\phi)V(\mu)$, $V(\mu)$ - дисперсионная функция.

Нормальное распределение

В случае нормального распределения:

$$\begin{aligned} f(y_i; \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{(y_i - \mu_i)^2}{2\sigma^2} \right] \\ &= \exp \left[\frac{y_i \mu_i - \frac{1}{2} \mu_i^2}{\sigma^2} - \frac{1}{2} \log(2\pi\sigma^2) - \frac{y_i^2}{2\sigma^2} \right] \end{aligned}$$

То есть:

$$b(\theta_i) = \frac{1}{2} \mu_i^2 = \frac{1}{2} \theta_i^2, \quad a(\phi) = \sigma^2, \quad c(y_i; \phi) = -\frac{1}{2} \log(2\pi\sigma^2) - \frac{y_i^2}{2\sigma^2}$$

Значит:

$$E(y_i) = b'(\theta_i) = \theta_i = \mu_i \quad \text{и} \quad \text{var}(y_i) = b''(\theta_i)a(\phi) = \sigma^2.$$

Характеристики некоторых распределений

Table 2.1 *Characteristics of some common univariate distributions in the exponential family*[†]

	<i>Normal</i>	<i>Poisson</i>	<i>Binomial</i>	<i>Gamma</i>	<i>Inverse Gaussian</i>
<i>Notation</i>	$N(\mu, \sigma^2)$	$P(\mu)$	$B(m, \pi)/m$	$G(\mu, \nu)$	$IG(\mu, \sigma^2)$
<i>Range of y</i>	$(-\infty, \infty)$	$0(1)\infty$	$\frac{0(1)m}{m}$	$(0, \infty)$	$(0, \infty)$
<i>Dispersion parameter: ϕ</i>	$\phi = \sigma^2$	1	$1/m$	$\phi = \nu^{-1}$	$\phi = \sigma^2$
<i>Cumulant function: $b(\theta)$</i>	$\theta^2/2$	$\exp(\theta)$	$\log(1 + e^\theta)$	$-\log(-\theta)$	$-(-2\theta)^{1/2}$
<i>$c(y; \phi)$</i>	$-\frac{1}{2} \left(\frac{y^2}{\phi} + \log(2\pi\phi) \right)$	$-\log y!$	$\log \binom{m}{my}$	$\nu \log(\nu y) - \log y - \log \Gamma(\nu)$	$-\frac{1}{2} \left\{ \log(2\pi\phi y^3) + \frac{1}{\phi y} \right\}$
<i>$\mu(\theta) = E(Y; \theta)$</i>	θ	$\exp(\theta)$	$e^\theta / (1 + e^\theta)$	$-1/\theta$	$(-2\theta)^{-1/2}$
<i>Canonical link: $\theta(\mu)$</i>	identity	log	logit	reciprocal	$1/\mu^2$
<i>Variance function: $V(\mu)$</i>	1	μ	$\mu(1 - \mu)$	μ^2	μ^3

[†]The mean-value parameter is denoted by μ , or by π for the binomial distribution.

The parameterization of the gamma distribution is such that its variance is μ^2/ν .

The canonical parameter, denoted by θ , is defined by (2.4). The relationship between μ and θ is given in lines 6 and 7 of the Table.

Бинарная регрессия



Пример задачи

- ▶ Местная клиника отправила своим клиентам предложение сделать прививку от гриппа для защиты от ожидаемой эпидемии.
- ▶ Через некоторое время у случайных 50 пациентов спросили сделали ли они прививку, при этом записывает информацию о возрасте и общем отношении к своему здоровью.
- ▶ Необходимо построить модель, которая предсказывает привит ли человек в зависимости от его возраста и отношения к здоровью.

Таким образом, мы говорим о модели, где $Y_i = \{0; 1\}$.

Регрессия с бинарными откликами: проблемы

- ▶ Для каждого ответа y у нас получается вероятностное распределение Бернулли с вероятностью успеха π_i :
- ▶ $P(Y_i = y_i) = \pi_i^{y_i} (1 - \pi_i)^{(1-y_i)}$. То есть:
 - среднее $\mu_i = E(Y_i) = \pi_i$;
 - дисперсия $Var(Y_i) = \pi_i(1 - \pi_i)$
- ▶ Таким образом дисперсия коррелирует со средним, обычные уравнения регрессии **не применимы**.

Регрессия с бинарными откликами: проблемы

Ещё одна проблема. Очевидная форма регрессии,

$$y_i = x_i\beta,$$

в левой части должна быть ограничена $(0; 1)$, правая часть же может расти неограниченно.

Идея: преобразование

- › Введём преобразование:

$$\text{logit}(\pi) = \log \left(\frac{\pi}{1 - \pi} \right) \in (-\infty; \infty);$$

- › обратная функция:



$$\text{logit}^{-1}(x) = \frac{e^x}{1 + e^x} \in (-1; 1);$$

- › производная:

$$\frac{d}{d\pi} \text{logit}(\pi) = \frac{1}{\pi(1 - \pi)} \sim \frac{1}{\text{Var}(\pi)}.$$

Идея: преобразование

- ▶ Три популярных преобразования:
 - $\text{Logit}(\pi) = \log \frac{\pi}{1-\pi}$;
 - $\text{Probit}(\pi) = \Phi^{-1}(\pi)$;
 - $\eta_i = \log(-\log(1 - \pi_i))$.
- ▶ Имеют разные интерпретации, используются для разных целей.



Итоговая постановка

Мы хотим максимизировать:

$$\mathcal{L}(\pi_i; Data) = \prod_{i=1}^n \pi_i^{Y_i} (1 - \pi_i)^{1-Y_i}$$

При этом, используя logit получаем:

$$\pi_i = \frac{e^{\beta_0 + \beta_1 X_i}}{1 + e^{\beta_0 + \beta_1 X_i}}$$

Подставляя в первое уравнение, получим:

$$\mathcal{L}((\beta_0; \beta_1); Data) = \prod_{i=1}^n \left(\frac{(e^{\beta_0 + \beta_1 X_i})^{Y_i}}{1 + e^{\beta_0 + \beta_1 X_i}} \right)$$

Интерпретация: логит

- ▶ Для простой модели с бинарной :

$$\text{logit}(\pi_i) = \beta_0 + \beta_1 x_i.$$

- ▶ Получается:

$$\text{logit}[P(y = 1 \mid x = 1)] - \text{logit}[P(y = 1 \mid x = 0)] = [\beta_0 + \beta_1(1)] - [\beta_0 + \beta_1(0)] = \beta_1$$

- ▶ То есть:

$$e^{\beta_1} = \frac{P(y = 1 \mid x = 1)/[1 - P(y = 1 \mid x = 1)]}{P(y = 1 \mid x = 0)/[1 - P(y = 1 \mid x = 0)]}$$

- ▶ β_1 имеет смысл логарифма отношения шансов.

Обобщённые линейные модели



Итоговая постановка

Для $f(y; \theta)$, принадлежащему экспоненциальному семейству распределений:

- ▶ **стохастическая** (random) **компонента** $y_i \sim f$;
- ▶ фиксированный линейный предиктор (**систематическая компонента**):

$$\eta_i = \beta_0 + \beta_1 x_{1,i} + \dots + \beta_{p-1} x_{p-1,i} ;$$

- ▶ **функция связи** (link function):

$$g(\mathbb{E}(y_i)) = \eta_i.$$

Функция связи

$$f(y_i; \theta_i, \phi) = \exp\{[y_i\theta_i - b(\theta_i)] / a(\phi) + c(y_i, \phi)\}$$

- ▶ Выбор функции связи $g(\cdot)$ зависит от распределения f .
- ▶ Обычно монотонна и дифференцируема в разрешённой области.
- ▶ **Канонической функцией связи**, g , для экспоненциального семейства называют функцию, которая связывает среднее μ и канонический параметр θ .
- ▶ Так как $\mu = b'(\theta)$, то $g(\mu) = (b')^{-1}(\mu)$.

GLM для нормального распределения

Выпишем три компоненты GLM:

- › $y_i \sim \mathcal{N}(\mu; \sigma)$ - случайная компонента.
- › $\eta_i = \sum x_{ij}\beta_j$ - линейный предиктор.
- › $g(\mu_i) = \mu_i$ - функция связи.

Тогда:

$$\mu_i = g(\mu_i) = \eta_i = \sum x_{ij}\beta_j.$$

Таким образом, общая линейная модель — частный случай обобщённой линейной модели.

Преимущества подхода GLM

- ▶ Позволяет одновременно контролировать качество распределений и их дисперсию*.
- ▶ Параметры модели описывают $g(\mathbb{E}(y_i))$, а не $\mathbb{E}(g(y_i))$.
- ▶ Сохраняет возможность интерпретации параметров.
- ▶ Унифицирует подход для часто встречающихся типов данных.

Поиск параметров



Лог-правдоподобие пример

$$\mathcal{L}((\beta_0; \beta_1); Data) = \prod_{i=1}^n \left(\frac{(e^{\beta_0 + \beta_1 X_i})^{Y_i}}{1 + e^{\beta_0 + \beta_1 X_i}} \right)$$

Вернёмся к примеру с бинарной регрессией:

$$\mathbb{E}[Y_i] = \pi_i = g^{-1}(\eta_i) = \frac{1}{1 + e^{-\eta_i}}$$

$$\begin{aligned} \mathcal{L}(\beta; \mathbf{y}) &= \prod_{i=1}^n \exp \left\{ y_i \log \left(\frac{\pi_i}{1 - \pi_i} \right) + \log(1 - \pi_i) \right\} \\ \log \mathcal{L}(\beta; \mathbf{y}) &= \sum_{i=1}^n y_i \log \left(\frac{\pi_i}{1 - \pi_i} \right) + \sum_{i=1}^n \log(1 - \pi_i) \\ &= \sum_{i=1}^n y_i \sum_{j=1}^p x_{ij} \beta_j - \sum_{i=1}^n \log \left(\exp \left\{ \sum_{j=1}^p x_{ij} \beta_j \right\} + 1 \right) \end{aligned}$$

Лог-правдоподобие GLM

- ▶ Аналогично:

$$\log \mathcal{L} = \sum \log \mathcal{L}_i = \sum \log f(y_i; \theta_i, \phi) = \sum \frac{y_i \theta_i - b(\theta_i)}{a(\phi)} + \sum c(y_i, \phi).$$

- ▶ Для модели $\eta_i = \sum_j \beta_j x_{ij} = g(\mu_i)$ поиск параметров сводится к:

$$\frac{\partial \mathcal{L}(\beta)}{\partial \beta_j} = \sum \frac{(y_i - \mu_i) x_{ij}}{\text{var}(y_i)} \frac{\partial \mu_i}{\partial \eta_i} = 0, \quad j = 1, \dots, p$$

- ▶ Получившееся уравнение нелинейно зависит от β_j . Необходимо решать итеративно.

Способы оптимизации

- ▶ метод Ньютона-Рафсона;
- ▶ метод IWLS (итерационный взвешенный метод наименьших квадратов);
- ▶ метод скоринга Фишера;
- ▶ стохастические методы;
- ▶ оценка максимального квази-правдоподобия.

Метод Ньютона-Рафсона

- ▶ Гессиан:

$$H: h_{ab} = \frac{\partial^2 \mathcal{L}(\boldsymbol{\beta})}{\partial \beta_a \partial \beta_b}.$$

- ▶ Для ряда Тейлора и $\mathbf{u} = \left(\frac{\partial \mathcal{L}}{\partial \beta_1}; \dots \frac{\partial \mathcal{L}}{\partial p} \right)^T$

$$\mathcal{L}(\boldsymbol{\beta}) \approx \mathcal{L}(\boldsymbol{\beta}^{(t)}) + \mathbf{u}^{(t)T} (\boldsymbol{\beta} - \boldsymbol{\beta}^{(t)}) + \frac{1}{2} (\boldsymbol{\beta} - \boldsymbol{\beta}^{(t)})^T H^{(t)} (\boldsymbol{\beta} - \boldsymbol{\beta}^{(t)}).$$

- ▶ Для $\frac{\partial \mathcal{L}(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} \approx \mathbf{u}^{(t)} + (H^{(t)})^{-1} (\boldsymbol{\beta} - \boldsymbol{\beta}^{(t)}) = 0$ итеративно решаем уравнение:

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} - (H^{(t)})^{-1} \mathbf{u}^{(t)}.$$

Метод Ньютона-Рафсона

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} - (\mathbf{H}^{(t)})^{-1} \mathbf{u}^{(t)}$$

- ▶ Метод хорошо работает для выпуклых случаев.
- ▶ Подход GLM для канонических функций связи позволяет гарантировать быструю сходимость:

$$\boldsymbol{\beta}^{(t+1)} \rightarrow \hat{\boldsymbol{\beta}}_{\text{ОМП}}$$




Figure 4.2 Illustration of a cycle of the Newton–Raphson method.

Метод скоринга Фишера

- ▶ Скоринг Фишера использует математическое ожидание Гессиана вместо самого Гессиана:

$$\mathcal{J}^{(t)} = -\mathbb{E} \frac{\partial^2 \mathcal{L}}{\partial \beta_a \partial \beta_b}, \text{ в точке } \beta = \beta^{(t)}$$

- ▶ Тогда шаг алгоритма выглядит так:

$$\beta^{(t+1)} = \beta^{(t)} - (\mathcal{J}^{(t)})^{-1} \mathbf{u}^{(t)}$$

При использовании канонической функции связи метод Ньютона-Рафсона и Фишера совпадают

Метод IWLS

- ▶ На практике часто используют метод итеративных взвешенных наименьших квадратов (частный случай метода скоринга Фишера):
 1. инициализировать значения $\hat{\mu}_i$ и $\hat{\beta}_j$ (для бинарной регрессии необходимо брать значения около 0 или 1 в зависимости от Y_i);
 2. оценить значение $Z_i = g(\hat{\mu}_i) + g'(\hat{\mu})(Y_i - \hat{\mu}_i)$;
 3. использовать веса $W^{-1} = g^2(\hat{\mu})V(\hat{\mu}_i)$ и применить обычную регрессию Z по X , получить $\hat{\beta}_j$;
 4. получить новую оценку $\hat{\mu} = g^{-1}(\sum X_{ij}\beta_j)$;
 5. повторить шаги 2-4 до сходимости.

Канонические функции связи

Использование канонических функций связи позволяет получить эквивалентные результаты в методах:

- ▶ Ньютона-Рафсона;
- ▶ IWLS (итерационный взвешенный метод наименьших квадратов);
- ▶ скоринга Фишера.

Качество



Критерии качества


- ▶ Получение *абсолютного* качества модели.
- ▶ Отбор переменных.
- ▶ Выбор моделей (получение *относительного* качества модели).

Квартеты Энскомба




Anscombe's Quartet

Each dataset has the same summary statistics (mean, standard deviation, correlation), and the datasets are *clearly different*, and *visually distinct*.




Unstructured Quartet

Each dataset here also has the same summary statistics. However, they are not *clearly different* or *visually distinct*.



Все 4 семейства имеют одинаковое среднее, дисперсии, уравнения регрессии, R^2 .

Квартеты Энскомба и Датазавр



Justin Matejka, George Fitzmaurice, Same Stats, Different Graphs, ACM SIGCHI Conference on Human Factors in Computing Systems 2017

Коэффициент детерминации



Определения коэффициента

- ▶ Хотим обобщить критерии качества, используемые для обычной линейной регрессии.
- ▶ Проблема: в GLM может быть корреляция между дисперсией и средним значением.
- ▶ $P(Y_i = y_i) = \pi_i^{y_i} (1 - \pi_i)^{(1-y_i)}$. То есть:
 - среднее $\mu_i = E(Y_i) = \pi_i$;
 - дисперсия $Var(Y_i) = \pi_i(1 - \pi_i)$

Определения коэффициента

- ▶ Для модели логистической регрессии:

$$\mathcal{P}(y_i = 1) = \mathbb{E}y_i = \pi_i = \frac{\exp(\alpha + \beta x_i + \dots)}{1 + \exp(\alpha + \beta x_i + \dots)};$$

- ▶ сумма квадратов:

$$SS_{RES} = \sum (y_i - \hat{\pi}_i)^2; SS_{MOD} = \sum (\hat{\pi}_i - \bar{y})^2; SS_{TOT} = \sum (y_i - \bar{y})^2.$$

Интерпретация коэффициентов

- ▶ Определения коэффициентов детерминации зависят от интерпретации:
 - $R_{MOD}^2 = \frac{SS_{MOD}}{SS_{TOT}}$ -- объяснённая моделью изменчивость;
 - $R_{RES}^2 = 1 - \frac{SS_{RES}}{SS_{TOT}}$ -- сравнение полной модели с тривиальной;
 - $R_{COR}^2 = r^2(y_i, \hat{\pi}_i)$ -- коэффициент корреляции между предсказаниями и данными.
- ▶ В общем случае, эквивалентны только асимптотически и при правильных коэффициентах модели. При этом хорошо работает в случай НМК и обычной линейной регрессии.

Tue Tjur Coefficients of Determination in Logistic Regression Models
The American Statistician, 63:4, 366-372

Псевдо- R^2

- ▶ Коэффициент дискриминации:

$$D = \bar{\hat{\pi}}_1 - \bar{\hat{\pi}}_0 = \sqrt{R_{MOD}^2 R_{RES}^2} = \frac{1}{2} (R_{MOD}^2 + R_{COR}^2)$$

- ▶ Замена сумм квадратов на правдоподобие:

$$R^2 = 1 - \frac{\ln \hat{\mathcal{L}}_{full}}{\ln \hat{\mathcal{L}}_{intercept}}$$

- ▶ Другие методы основаны на дополнении интерпретаций.

Проблемы R^2

- ▶ Низкие значения для реальных данных:
 - наблюдения всегда $\{0;1\}$, а предсказания могут быть $[0;1]$.
- ▶ Плохо разделяет близкие модели:
 - для $y_i = 0$ модели с $\hat{\pi}_i = 0.9$ и $\hat{\pi}_i = 0.99$ почти не отличаются, а $\mathcal{P}(y_i = 0)$ отличается в 10 раз.

Анализ остатков



Остатки

- ▶ В линейных моделях часто также анализируют остатки:

$$y_i - \hat{y}_i.$$

- ▶ В обобщённых моделях есть несколько схожих способов:

остатки Пирсона (для логрегрессии):

$$r_i = \frac{y_i - \pi_i}{\sqrt{\hat{\pi}_i(1 - \hat{\pi}_i)}}$$

остатки девианса (для логрегрессии):

$$d_i = s_i \sqrt{-2(y_i \log \hat{\pi}_i + (1 - y_i) \log(1 - \hat{\pi}_i))}$$

Из остатков конструируется статистика $D = \sum d^2$ и $X = \sum r^2$.

ДевIANса (Аномальность)

Мотивируясь отношением правдоподобий,

девиансой обобщённой линейной модели называется:

$$D(\hat{\mu}; y) = -2 (\log \mathcal{L}(\hat{\mu}; y) - \log \mathcal{L}(y; y)),$$

где $\hat{\mu}$ -- оценка y .

Девиианса (Аномальность)

- ▶ Для получения шкалы рассматривают два граничных случая:
 - **Насыщенная модель** – каждое уникальное наблюдение описывается одним из n параметров.
 - **Предложенная модель** – модель, подобранная в данном анализе.
 - **Нулевая модель** – все наблюдения описываются одним параметром (средним).
- ▶ Степени свободы (для p параметров модели):

$$df_{\text{saturated}} = 0; df_{\text{model}} = n - p_{\text{model}}; df_{\text{null}} = n - 1;$$

Интерпретация девиансы

Девианса - мера различия правдоподобий двух моделей:

- ▶ Девианса остатков

$$D_{\text{residual}} = 2(\log \mathcal{L}_{\text{saturated}} - \log \mathcal{L}_{\text{model}})$$

- ▶ Девианса нулевой модели

$$D_{\text{null}} = 2 \log \mathcal{L}_{\text{saturated}} - \log \mathcal{L}_{\text{null}}$$

Анализ девиансы

- ▶ Для тестирования значимости модели целиком:

$$LRT = 2 \log \left(\frac{\log \mathcal{L}_{\text{model}}}{\log \mathcal{L}_{\text{null}}} \right) = D_{\text{null}} - D_{\text{residual}}$$
$$df = df_{\text{null}} - df_{\text{model}} = p_{\text{model}} - 1$$

- ▶ Степени свободы (для p параметров):

$$LRT = 2 \log \left(\frac{\log \mathcal{L}_{\text{model}}}{\log \mathcal{L}_{\text{reduced}}} \right) = D_{\text{full}} - D_{\text{residual}}$$
$$df = df_{\text{full}} - df_{\text{model}} = p_{\text{model}} - p_{\text{reduced}}$$

Затем сравнение с χ^2 с df степенями свободы.

Обсуждение

- ▶ Анализ остатков даёт возможность ответить на вопросы о значимости модели и значимости добавления параметра.
- ▶ Аппроксимация χ^2 не очень устойчива, если групп значений у много.
- ▶ Можно использовать методы Хосмера-Лемешова: разбить на группы по вероятности и считать нужны естатистики.

Заклучение

- ▶ Стандартные подходы линейной регрессии плохо работают в случае отклонения шума от гомоскедастичности и нормальности.
- ▶ Преобразования данных ведут к плохой интерпретируемости модели и возможным проблемам с пунктом 1.
- ▶ Робастные оценки позволяют учитывать особенность распределения данных.
- ▶ Обобщённые линейные модели с канонической функцией связи позволяют проводить интерпретируемый анализ в случае ненормального шума.